

Previsão de Radiação Solar para Geração Fotovoltaica usando Machine Learning[★]

André Reis Rodrigues Filho^{*} Igor Ferreira Rocha^{**}
Yuri Lopes Gomes de Paulo^{***}

^{*} *Estudante de Engenharia Elétrica, Universidade Federal de São João del-Rei, MG (andrerrf.14@gmail.com).*

^{**} *Estudante de Engenharia Elétrica, Universidade Federal de São João del-Rei, MG (igorfn.vgp@gmail.com).*

^{***} *Estudante de Engenharia Elétrica, Universidade Federal de São João del-Rei, MG (yuric34@gmail.com).*

Abstract: Accurate assessment and forecasting of solar radiation are paramount for the strategic planning, reliability, and operational security of power systems. Given the growing complexity and the integration of variable renewable sources, traditional approaches often fail to capture the non-linear dynamics of the weather system. This article proposes a comparative performance analysis of three advanced machine learning methods applied to solar radiation forecasting. The methodology introduces a rigorous spatial preprocessing using DBSCAN clustering and clear-sky astronomical limits, followed by the training of three architectures: the Histogram Gradient Boosting Regressor (HGBR); the Nonlinear Autoregressive with Exogenous Inputs (NARX) model coupled with the FROLS algorithm; and a Ridge linear regression with prior feature selection via Lasso. To simulate the operational reality of a photovoltaic power plant, the models were evaluated under a free-run simulation regime using 2025 data, continuously feeding back their own predictions. Results demonstrate that the NARX-FROLS model achieved the best predictive performance, yielding the lowest Root Mean Square Error and the highest coefficient of determination R^2 . This architecture stood out for its faithful representation of temporal dynamics by integrating physical saturation limits.

Resumo: A avaliação e a previsão acuradas da radiação solar são pilares para o planejamento estratégico, a confiabilidade e a segurança operacional de sistemas de energia. Diante da crescente complexidade e da maciça inserção de fontes variáveis, abordagens tradicionais frequentemente falham ao tentar capturar as dinâmicas não lineares do clima. Este artigo propõe uma análise comparativa do desempenho de três métodos avançados de aprendizado de máquina aplicados à previsão de radiação solar. A metodologia introduz um rigoroso pré-processamento espacial utilizando clusterização DBSCAN e limites astronômicos de céu limpo, seguido pelo treinamento de três arquiteturas: o *Histogram Gradient Boosting Regressor* (HGBR); o modelo Autorregressivo Não Linear com Entradas Exógenas (NARX) acoplado ao algoritmo FROLS; e uma regressão linear Ridge com seleção prévia via Lasso. Para emular a realidade operacional de uma usina fotovoltaica, os modelos foram avaliados em regime de simulação livre (*Free-Run*) para o ano de 2025, retroalimentando suas próprias previsões. Os resultados demonstram que o modelo NARX-FROLS apresentou a performance superior, obtendo o menor Erro Quadrático Médio e o maior coeficiente de determinação R^2 , destacando-se na representação fiel das dinâmicas temporais por meio da integração de saturação física.

Keywords: Machine Learning; regression; HGBR; NARX-FROLS; Ridge after Lasso.

Palavras-chaves: Aprendizado de máquina; regressão; HGBR; NARX-FROLS; Ridge após Lasso.

1. INTRODUÇÃO

A transição energética e a crescente complexidade inerente à operação de sistemas elétricos têm demandado estimativas cada vez mais precisas e dinâmicas da radiação solar. No âmbito da Engenharia Elétrica, a previsibilidade do recurso solar é um parâmetro balizador para o planejamento

da expansão e para a segurança do suprimento, definindo a capacidade de geração que um sistema fotovoltaico pode sustentar. Com a progressiva integração de fontes renováveis intermitentes, a quantificação da disponibilidade de energia torna-se um desafio. A dependência intrínseca de variáveis climáticas introduz uma forte volatilidade que sobrepuja a capacidade dos métodos tradicionais de otimização estocástica, tornando indispensável o emprego de ferramentas preditivas avançadas.

[★] Disciplina Machine Learning aplicado à Engenharia, Curso de Engenharia Elétrica, Universidade Federal de São João del-Rei.

Este trabalho tem por finalidade mapear o comportamento dinâmico do recurso solar a partir de dados meteorológicos históricos aferidos pelo Instituto Nacional de Meteorologia (INMET (2025)). A identificação preliminar de padrões e dependências temporais motivou a estruturação de um *pipeline* preditivo que funde a engenharia de atributos baseada na astronomia local (radiação teórica de céu limpo) com técnicas de aprendizado de máquina supervisionado.

O escopo central consiste em avaliar e comparar três arquiteturas computacionais submetidas a um rigoroso regime de simulação livre (*Free-Run*) para a previsão contínua da radiação solar: o *Histogram Gradient Boosting Regressor* (HGBR), focado na extração de interações não lineares por meio de árvores de decisão; o modelo de identificação de sistemas dinâmicos NARX otimizado pelo algoritmo FROLS; e a abordagem linear híbrida Lasso-Ridge. O restante deste artigo está organizado da seguinte forma: a Seção 2 consolida a fundamentação teórica; a Seção 3 detalha o pré-processamento, a engenharia de atributos e o paradigma de simulação; a Seção 4 apresenta as métricas e a discussão do comportamento analítico dos preditores; e, por fim, a Seção 5 sintetiza as conclusões alcançadas.

1.1 Trabalhos Relacionados

A literatura recente em previsão de radiação solar tem convergido para arquiteturas híbridas e comparações sistemáticas entre famílias de modelos. Ali et al. (2025) propuseram um modelo de *ensemble* combinando Multi-Layer Perceptron, Redes Neurais Recorrentes e NARX para oito cidades com diferentes níveis de poluição atmosférica, evidenciando a robustez de arquiteturas autorregressivas exógenas frente a condições atmosféricas heterogêneas. De maneira complementar, Rashid et al. (2025) avaliaram oito modelos de aprendizado de máquina para radiação solar direta em seis regiões climaticamente distintas da Arábia Saudita, introduzindo uma codificação trigonométrica cíclica para variáveis temporais que corrobora diretamente a estratégia de engenharia de atributos adotada neste trabalho (seno e cosseno da hora do dia e do dia do ano). Já Silva et al. (2025) reforçam, em um estudo de planejamento energético de longo prazo, o papel consolidado dos métodos de *boosting* como XGBoost na estimativa do potencial solar sob diferentes condições climáticas, alinhando-se à motivação para a escolha do HGBR como uma das três arquiteturas comparadas.

Esses trabalhos recentes reforçam duas tendências que orientam a metodologia aqui proposta: (i) a integração de conhecimento físico-astronômico (como limites de céu limpo) como forma de restringir e estabilizar previsões puramente estatísticas; e (ii) a avaliação de modelos sob condições operacionais realistas, em vez de apenas sob regimes de previsão a um passo (*one-step-ahead*), o que motiva o uso do paradigma *Free-Run* adotado na Seção 3.3.

2. CONCEITOS PRELIMINARES

2.1 Histogram Gradient Boosting Regressor (HGBR)

O HGBR é um método de *ensemble* baseado em árvores de decisão de alta performance. Nesta arquitetura

de *boosting*, cada nova árvore é iterativamente treinada para minimizar o erro residual deixado pelos estimadores anteriores, ajustando-se à derivada da função de perda. Em distinção aos algoritmos de *Gradient Boosting* convencionais, o HGBR discretiza as variáveis contínuas em histogramas (ou *bins*), o que reduz drasticamente o custo computacional durante a busca pelos pontos ótimos de corte (*splits*) nos nós. Tal característica confere ao modelo alta escalabilidade e eficiência ímpar no mapeamento de não linearidades complexas oriundas de ciclos climáticos estocásticos (Ke et al., 2017). A implementação adotada é provida pela biblioteca scikit-learn (Pedregosa et al., 2011).

Estudos recentes seguem validando empiricamente essa característica em contextos de energia solar. Anirudh R. et al. (2024) desenvolveram um modelo de *ensemble* baseado em *gradient boosting* para previsão horária de Irradiância Global Horizontal (GHI) em múltiplas zonas climáticas da Índia, obtendo desempenho superior a modelos ARIMA, redes *feed-forward* e LSTM, o que reforça a competitividade de árvores de decisão *boostadas* frente a arquiteturas recorrentes mais complexas. De forma semelhante, Taha et al. (2025) compararam Gradient Boosting, Decision Tree e Random Forest para previsão de radiação solar de curto e longo prazo em Zafarana, Egito, destacando que variáveis temporais (hora, mês e ano) têm influência particularmente relevante em modelos baseados em árvores, achado que corrobora a inclusão de componentes cíclicos na matriz de atributos deste trabalho.

2.2 Modelagem Dinâmica (NARX e FROLS)

Nesta abordagem, a radiação solar transcende a representação tabular estática, sendo modelada como o estado de um sistema dinâmico contínuo. A estrutura Autorregressiva Não Linear com Entradas Exógenas (NARX) projeta a variável alvo $y(t)$ com base em suas próprias defasagens temporais e nos estados passados de variáveis exógenas $x(t)$:

$$y(t) = f(y(t-1), \dots, y(t-n_y), x(t-1), \dots, x(t-n_x)) + e(t), \quad (1)$$

onde $f(\cdot)$ é uma função de base não linear (tipicamente polinomial), n_y e n_x representam os atrasos máximos considerados e $e(t)$ denota o ruído do sistema.

Para mitigar a explosão combinatória inerente à expansão de termos polinomiais, acopla-se o algoritmo *Forward Regression Orthogonal Least Squares* (FROLS). Este método seleciona iterativamente os regressores que maximizam a redução da variância do erro. Como critério de interrupção, emprega-se o Critério de Informação Bayesiana (BIC), que penaliza matematicamente a complexidade geométrica para assegurar a formulação de um modelo parcimonioso e resistente ao sobreajuste (*overfitting*) (Aguirre, 2020).

A relevância prática dessa combinação segue sendo reafirmada na literatura mais recente. Ali et al. (2025) demonstraram que arquiteturas NARX mantêm desempenho competitivo mesmo sob condições atmosféricas adversas, como altos níveis de poluição, quando comparadas a redes neurais puramente *data-driven*. Já o pacote *NonSysId* (Billings et al., 2025) moderniza o algoritmo FROLS clássico por meio de uma seleção iterativa de termos orientada

à acurácia em simulação livre (*free-run*) (exatamente o regime de validação adotado neste trabalho) evidenciando que a integração entre parcimônia estrutural e desempenho em regime autônomo continua sendo uma frente de pesquisa ativa em identificação não linear de sistemas.

2.3 Regularização Lasso e Ridge

Com o intuito de estabelecer um referencial de performance (modelo *baseline*), foi projetado um regressor linear com regularização em cascata. O processo inicia-se com a expansão polinomial das variáveis climáticas. Dada a alta dimensionalidade resultante, aplica-se a regressão Lasso (*Least Absolute Shrinkage and Selection Operator*), que introduz uma penalidade L_1 à função de custo:

$$\hat{w} = \arg \min_w \left\{ \frac{1}{2n} \|Xw - y\|_2^2 + \alpha \|w\|_1 \right\}. \quad (2)$$

Essa restrição força os coeficientes associados a atributos pouco informativos ou redundantes a assumirem o valor exato de zero. O subconjunto de atributos sobreviventes é, então, submetido à regressão Ridge (penalidade L_2). O Ridge atua estabilizando os pesos de maneira uniforme entre variáveis correlacionadas, amortecendo a variância residual e mitigando a forte multicolinearidade presente nos dados meteorológicos (Hastie et al., 2009).

Essa estratégia em cascata (seleção via Lasso seguida de estabilização via Ridge) tem sido revisitada em trabalhos recentes de previsão de energia solar. Atiea et al. (2024) compararam Ridge, Lasso e Elastic Net como modelos de referência frente a estimadores baseados em árvore para previsão de potência fotovoltaica, concluindo que os métodos lineares regularizados, apesar de mais interpretáveis, tendem a subestimar picos de geração. Gomes and Martins (2025) chegaram a conclusão semelhante ao aplicarem Ridge sobre um espaço de atributos reduzido por análise fatorial, defendendo a interpretabilidade como vantagem central desses modelos frente a arquiteturas de aprendizado profundo. Por fim, Ferreira and Rocha (2025) combinaram Lasso e Ridge (via Elastic Net) para seleção de atributos em previsão de radiação solar em grandes altitudes, relatando ganhos de robustez frente à multicolinearidade, o mesmo problema que motiva a etapa de seleção prévia via Lasso neste trabalho.

3. METODOLOGIA

3.1 Filtragem Espacial e Tratamento de Dados

O conjunto de dados horários (2021 a 2025) proveniente do site do Intiuto Meteorológico (INMET (2025)) foi primeiramente submetido a um filtro espacial rigoroso mediante o algoritmo DBSCAN (*Density-Based Spatial Clustering of Applications with Noise*). Estações meteorológicas isoladas geograficamente ou pertencentes a aglomerados de baixa densidade (raio de vizinhança de 2 graus, cerca de 220 km) foram descartadas para suprimir vieses climáticos locais.

O emprego de algoritmos de clusterização densidade-dependente para o tratamento de séries de irradiância tem se mostrado uma estratégia consistente na literatura recente. Dou et al. (2024) propuseram um método de correção de previsões numéricas de tempo (NWP) para GHI baseado em clusterização por condições climáticas,

demonstrando ganhos de acurácia ao segmentar o problema de previsão por regime climático regional antes do treinamento dos modelos. Em um estudo comparativo mais recente, Lima and Pereira (2025) avaliaram diferentes técnicas de clusterização (incluindo o DBSCAN) aplicadas a dados de irradiância solar, discutindo a sensibilidade dos algoritmos densidade-dependentes aos parâmetros de vizinhança (ϵ) e ao número mínimo de amostras, o que reforça a necessidade de calibração cuidadosa do raio de 2 graus adotado neste trabalho.

Na prática, a escolha dos parâmetros do DBSCAN (ϵ e o número mínimo de pontos por vizinhança) impacta diretamente o equilíbrio entre a supressão de estações espúrias e a preservação de dados legítimos de regiões menos densamente monitoradas. Um valor de ϵ excessivamente pequeno tende a classificar estações isoladas, mas fisicamente válidas, como ruído, reduzindo desnecessariamente o volume de dados de treinamento; por outro lado, um ϵ excessivamente grande pode agregar estações climaticamente heterogêneas em um mesmo aglomerado, reintroduzindo o viés espacial que a filtragem busca eliminar. O raio de 2 graus (aproximadamente 220 km) adotado neste trabalho foi calibrado empiricamente de modo a equilibrar esses dois efeitos, mantendo a densidade mínima de estações necessária para a robustez estatística do conjunto de treinamento sem comprometer a homogeneidade climática dos aglomerados resultantes.

No tratamento de dados espúrios e períodos noturnos, utilizou-se a biblioteca *pvlb* para derivar a Irradiância Global Horizontal (GHI) Teórica de Céu Limpo por meio do modelo Ineichen-Perez. Esse modelo, amplamente adotado por sua implementação direta em Python e por seu bom desempenho com um conjunto mínimo de parâmetros de entrada, também foi utilizado recentemente por Bai et al. (2025) como conhecimento físico *a priori* para previsões ultrarrápidas de irradiância de 24 horas nos Estados Unidos, confirmando sua adequação como teto físico de referência em modelos orientados a dados. De forma complementar, Hwang (2025) propuseram uma abordagem físico-estatística para estimar a irradiância a partir de dados meteorológicos de superfície, reforçando a viabilidade de se combinar modelos astronômicos simplificados com variáveis medidas em estações terrestres, sem a necessidade de modelos espectrais de transferência radiativa computacionalmente custosos.

O alinhamento da medição física com os cálculos astronômicos permitiu: (i) distinguir com exatidão falhas de instrumentação de noites reais, anulando as medições onde a elevação solar encontrava-se abaixo do horizonte; e (ii) identificar e expurgar *outliers* sempre que a radiação aferida excedesse em 20% o limite físico imposto pelo modelo de céu limpo. Lacunas de curto prazo foram interpoladas linearmente no tempo, enquanto lacunas extensas sofreram imputação em cascata amparada em médias históricas.

3.2 Engenharia de Atributos e Lags

Visando incorporar a inércia atmosférica à inteligência dos algoritmos, construiu-se uma estrutura de janelas autorregressivas (*lags*) ancoradas em atrasos de curto e médio prazo (ex: 1h, 2h, 3h, 24h, 48h, etc.). Além das variáveis climáticas fundamentais (temperatura do ar, umidade re-

lativa e precipitação), a matriz de atributos foi enriquecida com componentes trigonométricos (seno e cosseno) alocados para a hora do dia e o dia do ano. Essa transformação viabiliza que os modelos assimilem de forma contínua a ciclicidade natural dos fenômenos terrestres, neutralizando a descontinuidade linear implícita às viradas de meia-noite e de ano. Essa mesma estratégia de codificação cíclica foi validada por Rashid et al. (2025), que reportaram ganhos mensuráveis na capacidade explicativa de atributos temporais ao aplicar transformações trigonométricas equivalentes em modelos de radiação solar direta.

3.3 Paradigma de Simulação Livre (*Free-Run*)

Para atestar a validade operacional dos modelos preditivos e extirpar qualquer otimismo ilusório, o conjunto de treinamento (2021 a 2024) foi instruído sob o paradigma de *Teacher Forcing*, alimentado integralmente com o gabarito das radiações passadas. Em contrapartida, a validação referente ao ano de 2025 ocorreu estritamente no regime de simulação *Free-Run*: os modelos foram privados do acesso aos dados reais de radiação. Consequentemente, cada passo temporal passou a consumir a predição imediatamente anterior retroalimentada, compondo de maneira autônoma a matriz de atrasos. Esse ambiente simula com alta fidelidade as restrições operacionais enfrentadas por usinas fotovoltaicas em cenários práticos de previsão de despacho, sendo compatível com a recomendação recente de Billings et al. (2025) de priorizar a acurácia em simulação livre como critério de seleção de modelos dinâmicos, em vez de se restringir à acurácia de previsão a um passo.

4. RESULTADOS E DISCUSSÃO

4.1 Métricas de Avaliação

Para quantificar objetivamente a aderência de cada arquitetura ao comportamento real da radiação solar, adotaram-se três métricas complementares, amplamente utilizadas na literatura recente de previsão de irradiância (Rashid et al., 2025; Taha et al., 2025). O Erro Absoluto Médio (*Mean Absolute Error*, MAE) quantifica a magnitude média dos desvios em unidades físicas da variável:

$$\text{MAE} = \frac{1}{n} \sum_{i=1}^n |y_i - \hat{y}_i|, \quad (3)$$

onde y_i é o valor real de radiação, $\hat{y}_i$ é a predição do modelo e n é o número de amostras no conjunto de teste. A Raiz do Erro Quadrático Médio (*Root Mean Square Error*, RMSE) penaliza mais fortemente grandes desvios pontuais, sendo especialmente sensível a picos mal previstos:

$$\text{RMSE} = \sqrt{\frac{1}{n} \sum_{i=1}^n (y_i - \hat{y}_i)^2}. \quad (4)$$

Por fim, o coeficiente de determinação R^2 expressa a proporção da variância dos dados reais que é explicada pelo modelo:

$$R^2 = 1 - \frac{\sum_{i=1}^n (y_i - \hat{y}_i)^2}{\sum_{i=1}^n (y_i - \bar{y})^2}, \quad (5)$$

onde $\bar{y}$ é a média dos valores reais de radiação no período avaliado. A combinação dessas três métricas permite não

apenas ordenar os modelos por desempenho médio (MAE, RMSE), mas também avaliar sua capacidade de captar a variabilidade global do fenômeno (R^2), o que é particularmente relevante no regime *Free-Run*, em que erros pontuais tendem a se propagar ao longo da janela de simulação.

A capacidade preditiva das três arquiteturas modeladas, operando integralmente sob o regime de simulação *Free-Run* para o ano de teste (2025), foi avaliada de forma quantitativa. A Tabela 1 resume o desempenho registrado.

Tabela 1. Comparação de Desempenho dos Modelos em Simulação *Free-Run* (2025)

Modelo	MAE (kJ/m²)	RMSE (kJ/m²)	R^2
NARX-FROLS	296,04	450,71	0,8366
HGBR	331,40	507,06	0,8031
Lasso + Ridge	434,85	565,61	0,7550

A estrutura NARX-FROLS demonstrou a melhor performance preditiva global, alcançando o menor RMSE e conseguindo explicar aproximadamente 83,6% da variância da radiação solar. O diferencial determinante desta formulação residiu na implementação de um mecanismo de *saturação física*: a cada iteração do ciclo *Free-Run*, a saída matemática do polinômio era limitada dinamicamente ao teto astronômico do GHI (céu limpo) correspondente àquele instante. Essa trava física inibiu a geração de instabilidades numéricas e cortou o efeito cascata de erros inerente à retroalimentação, resultando no delineamento das curvas diárias mais coesas e naturais. Esse resultado é consistente com o observado por Ali et al. (2025), cujo modelo baseado em NARX manteve vantagem de desempenho mesmo em cenários de maior variabilidade atmosférica, reforçando a robustez de arquiteturas autorregressivas exógenas quando associadas a restrições físicas adicionais.

O HGBR reiterou sua robustez como um estimador essencialmente *data-driven* ($R^2 = 0,8031$), valor compatível com a faixa reportada por Anirudh R. et al. (2024) para modelos de *gradient boosting* aplicados a diferentes zonas climáticas. Não obstante, sua arquitetura fundamentada na discretização por árvores produziu um inevitável efeito visual de quantização, caracterizado por degraus transitentes nas estimativas. Verificou-se, ainda, uma inércia de recuperação (*lagging*): diante de aberturas abruptas do tempo após chuvas, o modelo requeria um intervalo perceptível de horas retroalimentadas até restaurar seu patamar nominal de precisão, limitação também discutida por Taha et al. (2025) ao analisarem a sensibilidade de modelos baseados em árvore a transições climáticas abruptas.

O modelo linear híbrido (Lasso seguido de Ridge), designado como a base de controle, atingiu um R^2 de 0,7550. Sua rigidez estrutural resultou em um claro viés de regressão à média, traduzindo-se no achatamento contínuo dos picos de irradiação zenital e na respectiva superestimação dos vales crepusculares. A incapacidade de flexibilizar intensamente suas fronteiras de decisão impediu a aderência rigorosa ao perfil em formato de sino que define a geração fotovoltaica ideal. Esse comportamento replica o relatado por Atiea et al. (2024) e por Gomes and Martins (2025), para quem a vantagem de interpretabilidade dos modelos lineares regularizados é sistematicamente acompanhada

por perda de acurácia nos extremos da distribuição de irradiância.




Figura 1. Comparação temporal entre a radiação solar real e a estimada pelos modelos operando no regime de simulação *Free-Run.*, nos dias 16 a 19 de novembro de 2025, na estação A514 em São João del-Rei-MG.

Além disso, como pode ser observado na 1, o modelo composto por (Lasso seguido de Ridge) apresenta valores negativos de irradiância. Esse comportamento fica evidente no dia 16/11/2025 às 22 horas, momento em que o método previu aproximadamente -928 kJ/m^2 . Esse valor, além de negativo e com uma magnitude de energia considerável, ocorreu devido à natureza estritamente linear do método. Modelos de regressão linear regularizada tentam ajustar um hiperplano aos dados com o objetivo de minimizar o erro global. Como a equação matemática gerada é contínua e ilimitada, ou seja, não possui restrições físicas ou matemáticas para impedir valores abaixo de zero, a combinação dos pesos atribuídos às variáveis de entrada durante o período noturno acaba deslocando a previsão para o espectro negativo. Esse é precisamente o tipo de falha que a integração de limites físicos de céu limpo (como o modelo Ineichen-Perez utilizado por Bai et al. (2025)) busca evitar quando incorporada diretamente à etapa de pós-processamento das previsões.




Figura 2. Comparação temporal entre a radiação solar real e a estimada pelos modelos operando no regime de simulação *Free-Run.*, nos dias 10 a 13 de janeiro de 2025, na estação A514 em São João del-Rei-MG.

Conforme corrobora a análise visual da Figura 2, identificou-se uma limitação compartilhada entre todas as arquiteturas avaliadas: a incapacidade de prever reduções subitâneas e efêmeras na radiação solar (como a passagem de nuvens rápidas) sem que as variáveis exógenas (umidade ou chuva) apresentassem saltos proporcionais e precursoros. Em um cenário iterativo cego (*Free-Run*), oclusões meteorológicas isoladas não

podem ser deduzidas pelas equações de atraso se não manifestadas previamente nos dados térmicos. Essa limitação é amplamente reconhecida na literatura recente sobre previsão de irradiância baseada exclusivamente em dados de superfície, o que tem motivado a incorporação de imagens de céu e produtos de sensoriamento remoto como complemento às variáveis meteorológicas tradicionais (Hwang, 2025).

5. CONCLUSÕES

Este estudo evidenciou que a previsão da radiação solar sob regimes preditivos contínuos transcende a simples otimização de algoritmos numéricos, exigindo uma fusão profunda entre as técnicas de aprendizado de máquina e a física astronômica. A análise, conduzida sob o severo regime de simulação livre (*Free-Run*), confirmou o modelo dinâmico NARX-FROLS como a solução operacional mais segura. A seleção parcimoniosa das interações não lineares acoplada à imposição algorítmica dos limites de céu limpo impediu a degeneração matemática e o acúmulo sistêmico de erros temporais.

Em contrapartida, estruturas amparadas unicamente em inferência estocástica (como o *ensemble* HGBR e a regularização linear Lasso-Ridge) exibiram vulnerabilidades inerciais palpáveis ou severas distorções de escala (achatamento) ao tentarem replicar a mecânica fluida e cíclica do clima, muito embora o HGBR tenha mantido uma respeitável margem de acerto, compatível com os resultados reportados recentemente por Anirudh R. et al. (2024) e Taha et al. (2025) para arquiteturas de *boosting* equivalentes.

Como diretrizes para o desdobramento desta pesquisa, sugere-se a assimilação de dados provenientes de sensoriamento remoto (ex: matrizes de imagens orbitais ou índices de espessura ótica de nuvens via *nowcasting*) como complemento às variáveis exógenas de superfície, na linha do que já vem sendo explorado por modelos híbridos físico-estatísticos recentes (Hwang, 2025; Bai et al., 2025). Essa adição espacial teria o condão de suprimir a inércia dos modelos autorregressivos univariados, viabilizando a predição antecipada de intempéries localizadas e alcançando tais ferramentas a um grau de maturidade compatível com o despacho econômico de curtíssimo prazo. Adicionalmente, trabalhos futuros podem investigar a combinação do algoritmo FROLS com estratégias iterativas de seleção de termos orientadas à acurácia em simulação livre, tal como proposto por Billings et al. (2025), bem como a extensão da clusterização espacial de estações para métodos de segmentação por regime climático, conforme demonstrado por Dou et al. (2024) e Lima and Pereira (2025).

REFERÊNCIAS

- Aguirre, L.A. (2020). *Introdução à Identificação de Sistemas: Técnicas Lineares e Não Lineares Aplicadas a Sistemas Dinâmicos*. Editora UFMG, Belo Horizonte, 4 edition.
- Ali, M. et al. (2025). Neural network models for solar irradiance forecasting in polluted areas: A comparative study. *Energy Science & Engineering*, 14.
- Anirudh R., S., Krishnan, N., and Ravi Kumar, K. (2024). Solar radiation forecasting using gradient boosting ba-

- sed ensemble learning model for various climatic zones. *Results in Engineering*.
- Atiea, M.A., Shaheen, A.M., Alassaf, A., and Alsaleh, I. (2024). Enhanced solar power prediction models with integrating meteorological data toward sustainable energy forecasting. *International Journal of Energy Research*, 2024, 8022398. doi:10.1155/er/8022398.
- Bai, M., Fang, Z., Tao, S., Xiang, S., Bian, J., Xiang, Y., Zhao, P., Jin, W., Weyn, J.A., Dong, H., et al. (2025). Solarseer: Ultrafast and accurate 24-hour solar irradiance forecasts outperforming numerical weather prediction across the USA. *Cell Reports Physical Science*.
- Billings, S.A. et al. (2025). Nonsysid: Nonlinear system identification with improved model term selection for NARMAX models. Technical report, University of Sheffield.
- Dou, W., Wang, K., Shan, S., Li, C., Wang, Y., Zhang, K., Wei, H., and Sreeram, V. (2024). Day-ahead numerical weather prediction solar irradiance correction using a clustering method based on weather conditions. *Applied Energy*, 365. doi:10.1016/j.apenergy.2024.123239.
- Ferreira, I. and Rocha, I. (2025). A compound of feature selection techniques to improve solar radiation forecasting. *ResearchGate preprint*.
- Géron, A. (2020). *Mãos à Obra: Aprendizado de Máquina com Scikit-Learn e TensorFlow*. Alta Books, Rio de Janeiro, 2 edition.
- Gomes, R. and Martins, T. (2025). An interpretable statistical approach to photovoltaic power forecasting using factor analysis and ridge regression. *PMC*.
- Grus, J. (2020). *Data Science do Zero: Noções Fundamentais com Python*. Alta Books, Rio de Janeiro.
- Hastie, T., Tibshirani, R., and Friedman, J. (2009). *The Elements of Statistical Learning: Data Mining, Inference, and Prediction*. Springer, New York, 2 edition.
- Hwang, J. (2025). Estimation of solar spectral irradiance using meteorological data and analysis of optimal conditions for solar power generation. *arXiv preprint arXiv:2504.08008*.
- INMET (2025). Portal do instituto nacional de meteorologia. <https://portal.inmet.gov.br/>. Acesso em 2025.
- Ke, G., Meng, Q., Finley, T., Wang, T., Chen, W., Ma, W., Ye, Q., and Liu, T.Y. (2017). Lightgbm: A highly efficient gradient boosting decision tree. *Advances in Neural Information Processing Systems*, 30, 3146–3154.
- Lima, F. and Pereira, M. (2025). Two-level solar irradiance clustering with season identification: A comparative analysis. *arXiv preprint arXiv:2501.10084*.
- Müller, A.C. and Guido, S. (2016). *Introduction to Machine Learning with Python: A Guide for Data Scientists*. O'Reilly Media, Sebastopol.
- Nielsen, A. (2021). *Practical Time Series Analysis: Prediction with Statistics and Machine Learning*. O'Reilly Media, Sebastopol.
- Pedregosa, F., Varoquaux, G., Gramfort, A., Michel, V., Thirion, B., Grisel, O., Blondel, M., Prettenhofer, P., Weiss, R., Dubourg, V., Vanderplas, J., Passos, A., Cournapeau, D., Brucher, M., Perrot, M., and Duchesnay, E. (2011). Scikit-learn: Machine learning in Python. *Journal of Machine Learning Research*, 12, 2825–2830.
- Rashid, L.B., Shuja, S.Z., and Rehman, S. (2025). Machine learning forecasting of direct solar radiation: A multi-model evaluation with trigonometric cyclical encoding. *Forecasting*, 7(4), 58. doi:10.3390/forecast7040058.
- Silva, A., Santos, B., and Costa, C. (2025). Solar potential assessment using machine learning and climate change projections for long-term energy planning. *Scientific Reports*. doi:10.1038/s41598-025-23661-0.
- Taha, A., Makeen, P., and Nazih, N. (2025). Short-term and long-term solar irradiance forecasting with advanced machine learning techniques in Zafarana, Egypt. *Scientific Reports*, 15, 39553. doi:10.1038/s41598-025-24853-4.